BÁO CÁO ĐỀ TÀI :

Xây dựng hệ thống dữ liệu chứng khoán thời gian thực phục vụ phân tích và dự báo thị trường

Hệ thống thực nghiệm VNStockPulse

Sinh viên: Hoàng Bích Ngọc · Lớp BD_01
GVHD: Trần Thị Ngà, Mai Đức Thọ

Project đã làm được gì?

1. Thu thập

Lấy dữ liệu giá cổ phiếu Việt Nam (mở, cao, thấp, đóng, khối lượng) và lưu lên kho dữ liệu.

2. Xử lý

Làm sạch hơn 3,3 triệu dòng bằng Spark, tách riêng các dòng lỗi để kiểm tra.

3. Phục vụ

Cung cấp dữ liệu qua API và hiển thị trên dashboard biểu đồ giá, khối lượng.

4. Streaming thử nghiệm

Gửi 100 bản ghi qua Kafka để minh họa luồng dữ liệu liên tục.

5. Tự động hóa lịch

Airflow lên lịch thu thập dữ liệu mỗi ngày làm việc lúc 15:30.

Bài toán và phạm vi

Mục tiêu đề cương

Hệ thống thu thập và xử lý dữ liệu chứng khoán thời gian thực, làm nền cho phân tích và dự báo.

Phạm vi hiện tại

Dữ liệu giá theo phiên (OHLCV), xử lý theo lô, chạy bằng Docker Compose trên một máy.

Luồng dữ liệu tổng quát



Airflow lên lịch bước 1; Kafka là nhánh phát lại dữ liệu chạy riêng.

Mỗi tầng dùng công cụ gì?

Tầng	Công cụ	Vai trò
Thu thập	Python, VNStock	Lấy dữ liệu giá theo mã
Lưu trữ	MinIO (chuẩn S3), Parquet	Kho chứa file Raw, Bronze, Silver, Gold
Xử lý	Spark / PySpark	Làm sạch, kiểm tra, tách dòng lỗi
Phục vụ	DuckDB, FastAPI, Streamlit	Truy vấn, API, dashboard
Điều phối	Airflow, PostgreSQL	Lên lịch chạy, lưu trạng thái DAG
Streaming	Kafka, Schema Registry (Avro)	Truyền thông điệp có cấu trúc

Mô hình Bronze – Silver – Gold

Bronze: dữ liệu nạp

Dữ liệu thô từ Raw được đọc vào và giữ nguyên để làm điểm xuất phát.

Silver: dữ liệu đã kiểm tra

Áp dụng quy tắc giá hợp lệ; dòng lỗi được tách sang vùng dead_letter.

Gold: dữ liệu sẵn dùng

Bảng lịch sử và bản ghi mới nhất cho API và dashboard.

Mỗi lần chạy có một batch ID riêng để truy vết kết quả.

Phiên bản công nghệ đã dùng

Công nghệ	Phiên bản	Trạng thái
VNStock	4.0.8	Đã kiểm tra
MinIO SDK Python	7.2.20	Đã sử dụng
Spark / PySpark	3.5.3	Chạy thủ công
Airflow (LocalExecutor)	3.0.3	Đã cấu hình
Kafka, Schema Registry	Confluent 7.6.1	Chạy 100 bản ghi
DuckDB, FastAPI, Streamlit	Docker Compose	Đã hoạt động

Kết quả xử lý một batch

3.391.448
dòng Bronze

3.330.522
dòng Silver hợp lệ

60.926
dòng bị cách ly

1.521
dòng Gold latest (mỗi mã một dòng)

Silver hợp lệ + cách ly = Bronze. Gold history 3.330.522 dòng, đọc lại sau khi xuất vẫn khớp.

Kiểm tra chất lượng dữ liệu

1,80%
tỷ lệ dòng bị cách ly

98,20%
tỷ lệ dòng được giữ lại

Nhóm lỗi giá	Số dòng
bad_range (giá cao/thấp bất hợp lý)	55.316
Nhiều trường giá cùng lỗi	5.429
Nhóm lỗi còn lại	181

Tầng phục vụ: API tra cứu dữ liệu

Endpoint	Chức năng
/health	Kiểm tra dịch vụ đang chạy
/symbols	Danh sách mã cổ phiếu
/features/{symbol}	Dữ liệu và chỉ số của một mã
/market/latest	Bản ghi mới nhất toàn thị trường
/market/top-returns	Xếp hạng biến động giá

FastAPI đọc file Parquet qua DuckDB, không cần chạy lại Spark.

Dashboard Streamlit

Người dùng chọn

Mã cổ phiếu (ví dụ FPT), nguồn dữ liệu và số bản ghi hiển thị.

Dashboard hiển thị

Giá đóng cửa, thay đổi so với bản ghi trước, MA20, MA50, biểu đồ giá và khối lượng.

Bảng xếp hạng biến động

So với bản ghi hợp lệ trước đó, kèm khoảng cách ngày.

Truy vết

Mỗi dòng có raw_file, ingested_at, batch_id để lần ngược về Raw.

Kafka: luồng streaming thử nghiệm

Bước 1

Producer

Python + Avro

Đọc OHLCV có sẵn và gửi đi

→

Bước 2

Kafka

Topic vnstock.ohlcv.demo

Lưu thông điệp theo offset

→

Bước 3

Consumer

Giải mã Avro

Nhận 100 bản ghi

→

Bước 4

Kết quả

File JSONL

Có topic, partition, offset

Schema Registry giữ cấu trúc dữ liệu (subject vnstock.ohlcv.demo-value).

Airflow: điều phối theo lịch

Bước 1

Lịch

15:30 thứ Hai–Sáu

Cron 30 15 * * 1-5

→

Bước 2

Task 1

crawl_ohlcv

Thu thập dữ liệu giá

→

Bước 3

Task 2

publish_to_kafka

Đẩy dữ liệu lên Kafka

DAG vnstock_daily_ingestion đã được nhận. Chưa nối tự động Spark, Gold, export.

Đã làm được và còn phải làm

Đã làm được

Thu thập Raw; Medallion Bronze/Silver/Gold; cách ly dữ liệu lỗi; API và dashboard; Kafka demo; DAG Airflow.

Chưa làm

Nối tự động Airflow → Spark; đo độ trễ, thông lượng; tin tức, vĩ mô; Iceberg, Feature Store; mô hình dự báo.

Ưu tiên tiếp theo: nối tự động toàn bộ luồng, đối soát dữ liệu tháng 9, đo hiệu năng.

KẾT LUẬN

Đã xây dựng pipeline dữ liệu chứng khoán chạy từ thu thập đến dashboard

Xử lý hơn 3,3 triệu dòng, cách ly 1,80% bản ghi lỗi. Realtime thực sự và dự báo là bước tiếp theo.

Em xin cảm ơn thầy cô đã lắng nghe.